

O Céu em Dados: Análise exploratória em dados de Galáxias, Estrelas e Quasares

1° Carlos Vinicius S. Mesquita

dept. de Engenharia de Teleinformática
Universidade Federal do Ceará
Fortaleza, Brasil
carlos.mesquita12@alu.ufc.br

2° Francisco Vinicius Castro Silveira

dept. de Engenharia de Teleinformática
Universidade Federal do Ceará
Fortaleza, Brasil
viniciuscastro2615@alu.ufc.br

3° Thiago Siqueira de Sousa

dept. de Engenharia de Teleinformática
Universidade Federal do Ceará
Fortaleza, Brasil
thiago.siqueira@alu.ufc.br

Resumo—Este trabalho apresenta uma análise exploratória de dados do Sloan Digital Sky Survey (SDSS DR17), com o objetivo de identificar padrões estatísticos e relacionamentos entre variáveis fotométricas, posicionais e espectroscópicas de diferentes classes de objetos celestes: galáxias, estrelas e quasares. A partir de técnicas de análise univariada, bivariada e multivariada (PCA), foram observadas distribuições e correlações que revelam o comportamento característico de cada classe, com destaque para o redshift como variável mais discriminativa. As medidas fotométricas mostraram alta correlação linear, sugerindo a aplicação futura de regressões penalizadas (Ridge ou Lasso) para reduzir multicolinearidade em modelos preditivos. Além disso, verificou-se a necessidade de limpeza de dados na classe das galáxias, devido ao desbalanceamento entre classes. Os resultados obtidos fornecem uma base sólida para o desenvolvimento de modelos de aprendizado de máquina voltados à predição de redshift e à classificação automática de objetos astronômicos em levantamentos de larga escala.

Palavras-chave—SDSS DR17, galáxias, estrelas, quasares, EDA

I. INTRODUÇÃO

Galáxias, estrelas e quasares são objetos celestes centrais na astronomia, pois representam diferentes estágios e fenômenos fundamentais no universo. As galáxias constituem vastos sistemas gravitacionalmente ligados, formados por bilhões de estrelas, gás e poeira, que evoluem ao longo de bilhões de anos. Os quasares (quasi-stellar objects, QSO) correspondem a núcleos galácticos extremamente luminosos, cuja emissão de energia é alimentada pela acreção de matéria em torno de buracos negros supermassivos [1]. Já as estrelas são corpos luminosos compostos principalmente por hidrogênio e hélio, onde ocorrem reações de fusão nuclear responsáveis pela geração de energia e pela síntese dos elementos químicos que enriquecem o Universo [2].

O estudo desses corpos celestes requer coleta massiva de dados, obtidos por meio de instrumentos de alta precisão, como fibras ópticas, filtros fotométricos, câmeras e telescópios [3]. Esses dispositivos possibilitam a geração de conjuntos de dados detalhados que descrevem características físicas dos objetos observados, em formatos que variam entre imagens, tabelas, séries temporais e arquivos específicos da área, como os arquivos FITS (Flexible Image Transport System) [4]. Nesse contexto, o Sloan Digital Sky Survey (SDSS) destaca-se como

uma das iniciativas mais importantes da astronomia moderna, sendo responsável por alguns dos mais completos catálogos estelares do mundo. O dataset utilizado neste estudo pertence ao Data Release 17 (DR17) do SDSS e contém informações fotométricas e de posicionamento sobre galáxias, estrelas e quasares. As observações foram realizadas com o telescópio de 2,5 metros localizado no Apache Point Observatory, EUA, equipado com uma câmera composta por 30 sensores CCD dispostos em seis colunas e operando em modo de varredura contínua, o que possibilitou registrar imagens precisas nos cinco filtros fotométricos *u*, *g*, *r*, *i* e *z* [3].

Entre as grandezas físicas mensuradas, o redshift (desvio para o vermelho) destaca-se como uma das mais fundamentais para a classificação e caracterização de objetos celestes. Chatterjee e Ghosh [5] definem o redshift como a velocidade de um objeto devido à expansão do universo, fornecendo um indicador direto de sua distância cosmológica e, uma forte correlação com as propriedades físicas de alguns objetos.

A. Trabalhos Relacionados

Estudos posteriores com dados do SDSS têm se concentrado principalmente no desenvolvimento de modelos de classificação de galáxias, estrelas e quasares utilizando machine learning e deep learning. Veloso, Júnior e Rego [5] propõem uma rede multicamadas de perceptrons utilizando 17 variáveis do dataset para classificação de corpos celestes. Os trabalhos [6]–[8] focam em variáveis fotométricas como preditores em seus modelos de classificação. Esses estudos, assim como outros na literatura, concentram-se principalmente no desempenho preditivo dos modelos em detrimento da análise exploratória, que, quando realizada, limita-se a técnicas básicas.

Este trabalho busca preencher essa lacuna ao realizar uma análise exploratória aprofundada dos dados do SDSS DR17. Aplicando técnicas univariadas, bivariadas e multivariadas, investigamos a distribuição de características individuais, relações entre variáveis e análise envolvendo múltiplos atributos. Essa abordagem visa compreender melhor a estrutura e qualidade dos dados, identificando tendências, outliers e correlações relevantes que possam fundamentar futuros pré-processamentos para modelos de regressão e classificação.

II. MÉTODOS

Os métodos de análise exploratória empregados organizam-se em três fases. A primeira consiste na análise univariada, que examina individualmente cada variável por meio de estatísticas descritivas e visualizações, conduzida em abordagens incondicional e condicional. A segunda fase é a análise bivariada, que investiga relações entre pares de variáveis através de scatterplots e matriz de correlação. Por fim, aplica-se a Análise de Componentes Principais (PCA), uma técnica para analisar os dados de modo multivariado. Ao final desse estudo, foi incluído um apêndice com todas as tabelas de dados obtidos a partir das análises.

O trabalho foi desenvolvido em linguagem Python devido ao seu ecossistema voltado à EDA. Bibliotecas utilizadas foram Pandas para manipulação dos dados, NumPy para operações matriciais, Matplotlib e Seaborn para visualização.

A. Descrição do Dataset

O conjunto de dados bruto é tabular e estruturado em 18 colunas e 100000 amostras não duplicadas de corpos celestes. A tabela I informa com mais detalhes o que cada coluna do dataset representa.

TABELA I
DESCRIÇÃO DAS COLUNAS DO CONJUNTO DE DADOS SDSS DR17.

Coluna	Descrição
obj_ID	Identificador único do objeto no catálogo de imagens.
alpha	Ascensão Reta (Right Ascension) em coordenadas equatoriais.
delta	Declinação (Declination) em coordenadas equatoriais.
u	Magnitude no filtro ultravioleta (u).
g	Magnitude no filtro verde (g).
r	Magnitude no filtro vermelho (r).
i	Magnitude no filtro infravermelho próximo (i).
z	Magnitude no filtro infravermelho (z).
run_ID	Número da varredura do telescópio.
rerun_ID	Identifica o processamento da imagem.
cam_col	Coluna da câmera (CCD).
field_ID	Campo observado.
spec_obj_ID	Identificador único do objeto no catálogo espectroscópico.
class	Classe: galáxia, estrela ou quasar.
redshift	Desvio para o vermelho medido.
plate	Identificador da placa espectroscópica.
MJD	Data Juliana Modificada da captura.
fiber_ID	Fibra óptica usada na captura.

Para este estudo foram selecionadas as seguintes variáveis: alpha, delta, u, g, r, i, z, redshift, plate e MJD. Mantivemos as variáveis fotométricas e o redshift, classicamente utilizados como preditores de classificação [6]–[8]. Adicionalmente, incluímos as variáveis de posicionamento celestial (alpha, delta) e observacionais (plate, MJD) na expectativa de que possam revelar padrões relevantes para a caracterização dos objetos celestes. As variáveis de identificadores únicos foram descartadas por não contribuírem para a identificação de padrões generalizáveis. A variável cam_col também foi excluída por apresentar domínio inteiro restrito (1 a 6) com distribuição uniforme, oferecendo pouca capacidade discriminativa.

O conjunto de dados resultante possui $N = 99999$ amostras, $D = 10$ variáveis preditoras e $L = 3$ classes (galáxias, quasares e estrelas). Uma observação foi excluída por apresentar valores extremos identificados na análise de estatísticas

descritivas, descrita na subseção seguinte. A distribuição das classes é dada por $P(\text{Galáxia}) = 54.9\%$; $P(\text{Estrela}) = 21.6\%$ e $P(\text{Quasar}) = 19.0\%$.

B. Análise Univariada

A análise exploratória univariada foi conduzida mediante estatísticas descritivas, cálculo de coeficientes de assimetria e visualizações gráficas (histogramas e boxplots). Todas as análises foram realizadas de forma incondicional (considerando todo o conjunto de dados) e condicional (estratificadas por classe: galáxias, estrelas e quasares).

Para caracterizar a distribuição de cada variável preditora, foram calculadas sete medidas de posição e dispersão: média aritmética ($\bar{x}$), desvio padrão amostral (σ), valores mínimo e máximo, mediana (Q_2) e primeiro e terceiro quartis (Q_1 e Q_3). O desvio padrão amostral foi calculado segundo a Equação 1:

$$\sigma = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2} \quad (1)$$

A análise dessas estatísticas revelou uma estrela que apresentava valores de -9999 em múltiplas variáveis fotométricas, claramente inconsistentes com os intervalos interquartis das respectivas distribuições e indicando erro de medição ou registro. Esta amostra foi removida do conjunto de dados, resultando em $N = 99999$ observações válidas para as análises subsequentes.

Para quantificar a simetria das distribuições, calculou-se o coeficiente de assimetria (skewness, γ) para cada variável, tanto incondicionalmente quanto condicionalmente por classe. O coeficiente de assimetria é definido pela Equação 2:

$$\gamma = \frac{1}{N-1} \sum_{i=1}^N \left(\frac{x_i - \bar{x}}{\sigma} \right)^3 \quad (2)$$

Este coeficiente mede a assimetria da distribuição em torno da média: valores próximos a zero indicam distribuições aproximadamente simétricas; valores positivos indicam assimetria à direita; e valores negativos indicam assimetria à esquerda. A Tabela VI resume os coeficientes calculados, revelando que as características fotométricas possuem baixa assimetria, sendo a variável u uma das mais simétricas. Já o redshift possui assimetria à direita bem considerável. A análise condicional nos revela que os quasares são os responsáveis pela alta assimetria dessa variável já que $\gamma_{\text{quasar}} = 1.4981$ e $\gamma_{\text{galáxia}} \approx \gamma_{\text{estrela}} \approx 0.4$.

A Figura 1 apresenta os histogramas das distribuições incondicionais de todas as variáveis. As assimetrias quantificadas pelos coeficientes de skewness (Tabela VI) são visualmente evidentes nos histogramas: a variável redshift exibe assimetria à direita, com concentração de valores em magnitudes menores e cauda longa estendendo-se para valores maiores, consistente com seu coeficiente de skewness positivo elevado. As variáveis fotométricas apresentam distribuições aproximadamente unimodais com uma leve assimetria à esquerda. Por outro lado, as variáveis alpha, delta, plate e MJD não seguem distribuições paramétricas clássicas conhecidas.

A análise condicional dos histogramas (Figura 2) revela que o redshift apresenta distribuições distintas entre as três classes. Quasares exibem valores elevados e alta variância, com leve sobreposição com a faixa de galáxias, que concentram-se em valores intermediários com menor dispersão. Estrelas apresentam distribuição estreita centrada próxima a zero. Chatterjee e Ghosh [5] também observam esse padrão em suas análises e explicam pela física: estrelas apresentam redshifts ínfimos por estarem na Via Láctea; galáxias mostram redshifts moderados relacionados à sua distância e velocidade relativa; quasares exibem redshifts extremos devido às suas extremas distância da nossa galáxia. Esta separabilidade torna o redshift um preditor altamente informativo para classificação astronômica.




Figura 1. Histograma das 10 variáveis selecionadas.




Figura 2. Histograma condicional do redshift. A imagem demonstra as diferentes bandas típicas da característica para cada corpo celeste.

Os boxplots condicionais (Figura 3) revelam um padrão notável na distribuição do redshift entre as classes. A maioria dos quasares é identificada como outliers pelo critério de Tukey (pontos além de $1.5 \times IQR$ dos quartis), resultando em grande quantidade de pontos individualizados acima do limite superior da caixa. Este comportamento contrasta com as distribuições de galáxias e estrelas, que apresentam menor

proporção de valores extremos. Interpretamos esse fenômeno não como anomalias de medição, mas como reflexo das condições físicas extremas características dos quasares, resultando em redshifts naturalmente elevados e variados. A alta prevalência de "outliers" estatísticos para esta classe sugere que a definição convencional de valores extremos baseada em quartis pode não ser adequada para classificar a banda típica desses corpos.




Figura 3. Boxplot condicional do desvio pro vermelho. Percebemos aqui a quantidade de pontos identificados como outliers acima do bigode superior. A classe STAR possui uma distribuição muito estreita, visto anteriormente na Fig. 2.

C. Análise Bivariada

A análise bivariada foca no estudo das relações entre pares de variáveis preditoras, a fim de complementar a caracterização univariada. O objetivo é identificar a existência e a natureza linear das dependências, bem como a presença de potenciais *outliers* que possam impactar modelos preditivos.

Para isso, foram gerados gráficos de dispersão (*scatter plots*) para todas as $\binom{D=10}{2}$ combinações únicas de pares de preditores. Em cada gráfico, os pontos foram codificados por cores, de acordo com o rótulo de classe (Galáxia, Estrela ou Quasar) ao qual a amostra pertence, o que permite visualizar separabilidade das classes em um espaço bidimensional. O gráfico resultante é muito massante para ser exposto nesse estudo, mas está disponível no repositório do trabalho. Incluímos aqui apenas uma pequena poção desses gráficos na Fig. 5.

A dependência linear entre os preditores é quantificada por meio do coeficiente de correlação de Pearson para a par ρ_{d_i, d_j} , com $d_i, d_j = 1, \dots, D$. O coeficiente ρ mede a força e a direção da relação linear, variando entre -1 (correlação linear negativa perfeita) e $+1$ (correlação linear positiva perfeita). Os coeficientes foram organizados em uma matriz de correlação $\mathbf{R}$, onde $\mathbf{R}(i, j) = \rho_{d_i, d_j}$. Esta matriz é apresentada na Fig. 4 como um mapa de calor para facilitar a visualização das intensidades das correlações.

A matriz de correlação de Pearson (Figura 4) revela forte correlação linear entre as variáveis fotométricas, particularmente nas bandas de comprimentos de onda maiores. As variáveis r , i e z apresentam coeficientes de correlação superiores a 0,9, indicando alta redundância informacional. A Figura 5 apresenta os gráficos de dispersão entre esses pares

de variáveis, evidenciando relações lineares positivas bem definidas.




Figura 4. Mapa de calor da matriz de correlação de Pearson entre as 10 variáveis preditoras selecionadas. Nota-se que as variáveis fotométricas são bastante correlacionadas entre si.




Figura 5. Scatterplot das medidas fotométricas voltadas ao vermelho, juntamente com suas respectivas distribuições na diagonal.

Adicionalmente, observa-se correlação altíssima entre as variáveis instrumentais plate e MJD ($\rho = 0.97$), sugerindo que diferentes placas fotográficas foram sistematicamente utilizadas em períodos temporais distintos durante o levantamento observacional. As variáveis fotométricas também apresentam correlações não consideráveis com MJD, indicando um comportamento temporal não explícito. Por outro lado, as coordenadas celestes (alpha, delta) mostram correlações próximas

a zero com as demais variáveis, confirmando sua natureza puramente posicional e independente das propriedades físicas observadas.

Até agora, elucidou-se a importância do redshift para a caracterização dos corpos celestes, então podemos pensa-la também como uma variável alvo de predição por modelos de inteligência computacional, especialmente de regressão. Preditores possíveis incluiriam as aferições fotométricas e a data da captura em MJD. As variáveis de posicionamento alpha e delta não seriam consideradas preditoras.

D. Análise de Componentes Principais

A análise de componentes principais (PCA) é um algoritmo de aprendizado de máquina não supervisionado que transforma um conjunto de variáveis correlacionadas em um novo conjunto de variáveis não correlacionadas. Os novos eixos, denominados componentes principais (PCs), são ordenados de forma decrescente segundo a variância dos dados originais que explicam. Matematicamente, o PCA identifica os autovetores da matriz de covariância (ou correlação) dos dados, onde cada PC é uma combinação linear das variáveis originais que maximiza a variância capturada sob a restrição de ortogonalidade com as componentes anteriores.

Abdi e Williams [9] definem os objetivos do PCA como sendo: (1) extrair as informações mais importantes dos dados; (2) comprimir a dimensionalidade dos dados; (3) simplificar a descrição dos dados; (4) analisar a estrutura das variáveis. No contexto deste estudo, aplicamos PCA para investigar o quanto as 10 variáveis preditoras selecionadas descrevem os dados originais e como se pode representá-los em menor dimensionalidade sem perda significativa de informação.

O algoritmo usado no estudo foi feito implementando a abstração em pseudocódigo no Listado 1. Não foram utilizadas bibliotecas de machine learning com PCA já pronto. Importante ressaltar que, no geral, os dados X são centralizados antes da PCA [9] devido a sensibilidade do algoritmo; aqui, incluímos a padronização como parte do procedimento.

Ressalta-se também que o redshift foi excluído desta análise, uma vez que, agora, sob a perspectiva de um problema de regressão futuro, esta variável atua como target e não como preditor. Assim, o PCA foi aplicado às 9 variáveis preditoras remanescentes (alpha, delta, u, g, r, i, z, plate, MJD) para investigar a possibilidade de redução de dimensionalidade no espaço de entrada, preservando informação relevante para predição do redshift.

As Figuras 6 e 7 foram obtidas a partir da PCA sobre as amostras. Visualiza-se no screeplot da Fig. 6 que com duas componentes principais podemos descrever 73% da variância dos dados e que pelo quatro dimensões possuem uma variância explicada de $\lambda_i \leq 1\%$, formando um *plateau* no gráfico. A Fig. 7 ilustra a projeção das amostras no plano duas PCs. Ainda que nesse plano haja uma grande retenção de informação, não é possível notar uma segmentação nítida das classes.

Algorithm 1 Análise de Componentes Principais (PCA)

Entrada: Matriz de dados $\mathbf{X} \in \mathbb{R}^{N \times D}$, número de componentes $k \leq D$

Saída: Matriz de componentes principais $\mathbf{Z} \in \mathbb{R}^{N \times k}$, matriz de autovetores $\mathbf{W} \in \mathbb{R}^{D \times k}$

- 1: Calcular a média μ e o desvio padrão σ de cada variável
- 2: Padronizar: $\mathbf{X}_s = (\mathbf{X} - \mathbf{1}_N \mu^T) \oslash \sigma^T$
- 3: Matriz de covariâncias: $\mathbf{C} = \frac{1}{N-1} \mathbf{X}_s^T \mathbf{X}_s$
- 4: Calcular autovalores $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_D$ e autovetores $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_D$ de $\mathbf{C}$, de modo que $\mathbf{C} \mathbf{v}_i = \lambda_i \mathbf{v}_i$
- 5: Primeiros k autovetores: $\mathbf{W} = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k]$
- 6: Dados projetados: $\mathbf{Z} = \mathbf{X}_s \mathbf{W}$
- 7: **retorna:** $\mathbf{Z}, \mathbf{W}$, autovalores $\{\lambda_i\}_{i=1}^k$




Figura 6. Scree Plot mostrando a variância explicada por cada componente principal (PCA). Cada ponto representa a porcentagem da variância total capturada pela respectiva componente, permitindo identificar quantos PCs são suficientes para representar a maior parte da informação dos dados.




Figura 7. Projeção dos dados nas duas primeiras componentes principais (PC1 e PC2). Cada ponto representa uma amostra no espaço reduzido pelo PCA, permitindo a visualização de dispersão. Visualiza-se alta sobreposição de agrupamentos.

III. RESULTADOS

A análise exploratória dos dados do SDSS DR17 revelou características distintas entre galáxias, estrelas e quasares, evidenciando padrões que fundamentam a aplicação de técnicas

de aprendizado de máquina para classificação e regressão desses objetos celestes.

O redshift aparece como a variável mais discriminativa entre as classes. Conforme observado nos histogramas condicionais (Fig 2) e boxplots (Fig. 3), estrelas concentram-se em redshifts muito pequenos ($\mu \approx 0, \sigma \approx 0$), galáxias distribuem-se em valores moderados ($\mu = 0.42, \sigma = 0.26$), e quasares apresentam redshifts elevados ($\mu = 1.72, \sigma = 0.91$) com alta variabilidade. A análise de skewness confirma esse padrão: o coeficiente incondicional $\gamma = 2.5236$ é dominado pela contribuição dos quasares ($\gamma_{\text{quasar}} = 1.4981$), enquanto galáxias e estrelas apresentam assimetrias moderadas ($\gamma_{\text{galáxia, estrela}} \approx 0.4$).

A análise de componentes principais revelou que, embora 72.9% da variância seja capturada em duas componentes, essa compressão não garante separabilidade clara entre as classes. A concentração de 59.5% da variância em PC1 reflete a alta correlação entre variáveis fotométricas, sugerindo um eixo comum de intensidade luminosa. Notavelmente, quatro componentes apresentam variância inferior a 1% (Fig. 6), consistente com os quatro pares de variáveis altamente correlacionadas ($\rho > 0.9$) na matriz de correlação (Fig. 4). Essa correspondência indica colapso dimensional devido à redundância da informação. A sobreposição observada na projeção bidimensional (Fig. 7) sugere que agrupamentos mais claros entre as classes podem residir em uma projeção com mais PCs ou em estruturas não-lineares não capturadas pelo PCA.

O estudo foi importante para fundamentar as decisões relacionadas ao pré-processamento dos dados para futuros modelos de regressão do redshift. A distribuição das variáveis é, em geral, satisfatoriamente simétrica, de modo que não se faz necessária a aplicação de transformações logarítmicas para correção de assimetria. No que diz respeito à seleção de preditores, opta-se por manter todas as variáveis fotométricas, uma vez que são tradicionalmente utilizadas na literatura e possuem relevância física direta, verificável nos estudos [6]–[8]. Entretanto, conforme demonstrado na análise bivariada, essas variáveis exibem forte correlação linear, o que implicará a necessidade de empregar regressões penalizadas, como Ridge ou Lasso, para reduzir a multicolinearidade e garantir estabilidade numérica dos modelos.

Entre as variáveis instrumentais e observacionais, recomenda-se manter apenas a variável MJD como preditor, por sua possibilidade de capturar padrões temporais não explícitos. Em contrapartida, plate deve ser removida devido à sua correlação quase perfeita com MJD ($\rho = 0.97$), o que tornaria redundante sua inclusão no modelo. Da mesma forma, as coordenadas alpha e delta serão descartadas, pois, conforme observado, possuem natureza puramente posicional e correlações desprezíveis com as demais variáveis, não contribuindo para a explicação do redshift.

A análise também indicou a necessidade de uma etapa de limpeza de dados, especialmente na classe das galáxias, que apresenta alta frequência no conjunto ($P(\text{Galáxia}) = 54.9\%$) e, portanto, pode introduzir viés em modelos supervisionados. Beck et al. [10], ao trabalharem exclusivamente com galáxias do SDSS DR12, demonstram uma abordagem empírica para

detecção de outliers, baseada em intervalos específicos de combinações de variáveis fotométricas. Essa metodologia pode servir como referência para o desenvolvimento de uma técnica análoga aplicada ao DR17, visando eliminar valores discrepantes e equilibrar o conjunto de dados.

No caso dos quasares, embora a quantidade de outliers seja elevada, opta-se por não removê-los neste momento, visto que constituem uma classe minoritária ($P(\text{QSO}) = 19.0\%$) e que a variabilidade extrema pode advir das condições físicas extremas desses objetos. Posteriormente, pode-se avaliar técnicas de detecção de anomalias análogas às aplicadas em galáxias, preservando a representatividade da classe.

Em síntese, esta análise exploratória não apenas permitiu compreender a estrutura estatística dos dados do SDSS DR17, mas também forneceu ideias para o pré-processamento e modelagem preditiva do redshift. As descobertas aqui apresentadas estabelecem uma base sólida para estudos subsequentes de regressão e classificação, contribuindo para o avanço de métodos computacionais aplicados à observação de objetos celestes.

REFERÊNCIAS

- [1] G. Kauffmann and M. Haehnelt, “A unified model for the evolution of galaxies and quasars” *Mon. Not. R. Astron. Soc.*, vol. 311, pp. 576–588, 2000.
- [2] E. M. Burbidge, G. R. Burbidge, W. A. Fowler, and F. Hoyle, “Synthesis of the elements in stars,” *Rev. Mod. Phys.*, vol. 29, no. 4, pp. 547–650, Oct. 1957.
- [3] Sloan Digital Sky Survey, “Instruments,” SDSS, 2025. [Online]. Available: <https://www.sdss.org/instruments/>.
- [4] Abdurro’uf, N., K. Accetta, C. Aerts, et al. 2022. “The Seventeenth Data Release of the Sloan Digital Sky Surveys: Complete Release of MaNGA, MaStar, and APOGEE-2 Data.” *Astrophysical Journal. Supplement Series* 259, no. 2: 1–39.
- [5] E. Veloso, G. Júnior e R. Rego, “Modelo Perceptron Multicamadas para Classificação de Estrelas, Quasares e Galáxias,” Universidade Federal Rural do Semi-Árido, Pau dos Ferros, RN, Brasil, 2023.
- [6] D. Chatterjee and P. Ghosh, “Redshift-Agnostic Machine Learning Classification: Unveiling Peak Performance in Galaxy, Star, and Quasar Classification (Using SDSS DR17),” *Astronomische Nachrichten*, 2025.
- [7] D. Omat, O. Otey, and A. Al-Mousa, “Stellar Objects Classification Using Supervised Machine Learning Techniques,” in *Proc. 2022 Int. Arab Conf. on Information Technology (ACIT)*, Amman, Jordan, 2022.
- [8] F. R. Llorella and J. A. Cebrián, “Exploring Symbolic Regression and Genetic Algorithms for Astronomical Object Classification,” *arXiv preprint arXiv:2503.09220 [astro-ph.GA]*, Mar. 2025.
- [9] H. Abdi and L. J. Williams, “Principal component analysis,” *Wiley Interdisciplinary Reviews: Computational Statistics*, vol. 2, no. 4, pp. 433–459, 2010.
- [10] R. Beck, L. Dobos, T. Budavári, A. S. Szalay, and I. Csabai, “Photometric redshifts for the SDSS Data Release 12,” *Monthly Notices of the Royal Astronomical Society*, vol. 460, no. 2, pp. 1371–1381, 2016.

APÊNDICE A TABELAS DE DADOS CALCULADOS

TABELA II
ESTATÍSTICAS DESCRITIVAS INCONDICIONAIS

Medida	alpha	delta	u	g	r	i	z	redshift	plate	MJD
mean	177.63	24.14	22.08	20.63	19.65	19.08	18.77	0.58	5137.03	55588.65
std	96.50	19.64	2.25	2.04	1.85	1.76	1.77	0.73	2952.31	1808.49
min	0.01	-18.79	11.00	10.50	9.82	9.47	9.61	-0.01	266.0	51608.0
25%	127.52	5.15	20.35	18.97	18.14	17.73	17.46	0.05	2526.0	54234.0
50%	180.90	23.65	22.18	21.10	20.13	19.41	19.00	0.42	4987.0	55869.0
75%	233.90	39.90	23.69	22.12	21.04	20.40	19.92	0.70	7400.5	56777.0
max	360.00	83.00	32.78	31.60	29.57	32.14	29.38	7.01	12547.0	58932.0

TABELA III
ESTATÍSTICAS DESCRITIVAS - GALÁXIAS

Medida	alpha	delta	u	g	r	i	z	redshift	plate	MJD
mean	177.95	23.51	22.59	20.91	19.59	18.85	18.45	0.42	4869.38	55423.46
std	94.40	19.32	2.26	2.11	1.87	1.69	1.66	0.26	2858.33	1806.05
min	0.01	-12.36	13.90	12.68	11.75	11.30	10.90	-0.01	266.0	51608.0
25%	131.51	5.17	20.79	18.91	17.82	17.38	17.10	0.16	2172.0	53845.0
50%	181.32	22.30	22.84	21.58	20.10	19.22	18.77	0.46	4770.0	55830.0
75%	231.33	37.97	24.21	22.45	20.97	19.95	19.47	0.59	6792.0	56543.0
max	359.99	77.62	29.33	31.60	29.57	30.16	29.38	2.00	12547.0	58932.0

TABELA IV
ESTATÍSTICAS DESCRITIVAS - QUASARES

Medida	alpha	delta	u	g	r	i	z	redshift	plate	MJD
mean	180.47	26.81	21.55	20.93	20.62	20.43	20.27	1.72	6943.07	56627.55
std	98.96	19.59	1.50	1.16	1.08	1.08	1.10	0.91	2792.09	1579.82
min	0.01	-15.98	11.00	13.66	12.36	12.64	11.30	0.00	267.0	51608.0
25%	129.13	7.43	20.64	20.25	20.01	19.81	19.64	1.11	5005.0	55868.0
50%	183.68	29.30	21.50	21.06	20.77	20.58	20.37	1.62	7574.0	56955.0
75%	235.86	42.89	22.29	21.69	21.41	21.20	21.00	2.22	8746.0	57870.0
max	360.00	82.29	32.78	27.89	27.40	32.14	28.79	7.01	12547.0	58932.0

TABELA V
ESTATÍSTICAS DESCRITIVAS - ESTRELAS

Medida	alpha	delta	u	g	r	i	z	redshift	plate	MJD
mean	174.23	23.50	21.15	19.62	18.95	18.54	18.33	-0.00	4287.97	55131.16
std	99.88	20.38	2.36	2.12	1.97	1.84	1.84	0.00	2691.84	1656.30
min	0.03	-18.79	12.10	10.50	9.82	9.47	9.61	-0.00	267.0	51608.0
25%	114.85	3.13	19.33	18.03	17.45	17.14	16.96	-0.00	2318.0	53905.0
50%	174.15	23.40	21.01	19.54	18.96	18.59	18.32	-0.00	3296.0	54924.0
75%	240.85	39.94	22.96	21.23	20.56	20.04	19.73	0.00	6386.0	56365.0
max	360.00	83.00	30.66	30.61	29.37	30.25	26.43	0.00	12547.0	58932.0

TABELA VI
COEFICIENTES DE ASSIMETRIA (SKEWNESS)

Variável	Incondicional	Galáxias	Quasares	Estrelas
alpha	-0.0285	-0.0576	-0.0524	0.0639
delta	0.1751	0.2523	-0.0733	0.1908
u	-0.0703	-0.2792	0.4325	0.1282
g	-0.4280	-0.5368	-0.2441	0.0970
r	-0.5079	-0.4159	-0.7617	-0.0367
i	-0.4042	-0.2947	-0.6374	-0.1020
z	-0.2568	-0.1341	-0.6455	0.0062
redshift	2.5236	0.4127	1.4981	0.4260
plate	0.1985	0.2041	-0.4992	0.7686
MJD	-0.3819	-0.3948	-1.1857	0.1222

TABELA VII
VARIÂNCIA EXPLICADA POR COMPONENTE PRINCIPAL

Componente	Variância Explicada	Variância Acumulada
PC1	0.59547	0.59547
PC2	0.13354	0.72902
PC3	0.10686	0.83588
PC4	0.08910	0.92498
PC5	0.05751	0.98250
PC6	0.01025	0.99275
PC7	0.00319	0.99593
PC8	0.00249	0.99843
PC9	0.00157	1.00000